

# 23-24 计算物理第一次习题课

## 线性代数知识补充

2023 年 10 月 17 日

- ① **矩阵的本征值问题**  
用于第七讲矩阵的分解
- ② **矩阵的模**  
介绍矩阵的模（范数）

# 矩阵的本征值与本征矢量

## 本征值与本征矢量定义

对于方阵  $A$ ，如果存在一个标量  $\lambda$  和一个非零矢量  $v$ ，使得以下关系成立：

$$Av = \lambda v$$

其中， $\lambda$  称为矩阵  $A$  的本征值， $v$  称为对应于本征值  $\lambda$  的本征向量。

## 本征值的求解方法

要找到矩阵  $A$  的本征值和本征向量，我们需要解以下方程：

$$Av = \lambda v$$

这是一个特征方程，可以通过解特征多项式来求解  $\lambda$ ，特征多项式为：

$$\det(A - \lambda I) = 0$$

其中， $I$  是单位矩阵。


# 本征值与本征矢量

## 本征矢量的含义和求解方法

本征矢量是线性变换中的特殊方向，它们保持在变换后方向不变。本征矢量可以通过求解特征方程得到：

$$A\mathbf{v} = \lambda\mathbf{v}$$

其中， $\lambda$  是本征值， $\mathbf{v}$  是对应的本征矢量。




## 本征矢量张成本征空间

本征矢量  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$  对应于矩阵  $A$  的不同本征值  $\lambda_1, \lambda_2, \dots, \lambda_n$ ，它们张成了矩阵  $A$  的本征空间。

- 矩阵  $A$  的每个本征值都对应一个唯一的本征空间。

# 特征多项式与多重度



## 特征多项式

特征多项式为:

$$(\lambda - \lambda_0)^2 \times \dots = 0$$

## 代数多重度与几何多重度

- **代数多重度:** 代表特征根在特征多项式中出现的次数。2。
- **几何多重度:** 几何多重度表示为  $\dim(\ker(\mathbf{A} - \lambda\mathbf{I}))$ , 它表示与特征值  $\lambda_0$  相关联的本征矢量的数量

# 相似变换与本征值

## 相似变换的定义

对于两个  $n \times n$  矩阵  $A$  和  $B$ , 如果存在一个可逆矩阵  $P$ , 使得以下关系成立:

$$B = P^{-1}AP$$

则称矩阵  $A$  与  $B$  相似, 矩阵  $P$  称为相似变换矩阵。

## 相似变换保持本征值

证明: 假设  $A$  和  $B$  相似, 即  $B = P^{-1}AP$ , 其中  $P$  是可逆矩阵。

假设  $A\mathbf{v} = \lambda\mathbf{v}$ ,  $\mathbf{w} = P^{-1}\mathbf{v}$ 。

那么  $B\mathbf{w} = P^{-1}AP\mathbf{w} = P^{-1}\lambda\mathbf{v}$ 。

因此  $B\mathbf{w} = \lambda\mathbf{w}$

## 么正变换

可逆矩阵  $P$  为么正矩阵  $U$  满足  $U^\dagger U = UU^\dagger = I$

- 相似变换可以通过将矩阵对角化或者准对角化来求解矩阵的特征值。

## Schur 分解

对于任意一个方阵  $A$ ，存在一个幺正矩阵 (unitary matrix)  $U$ ，使得  $U^\dagger A U$  是一个上三角矩阵 (upper triangular matrix)。

换句话说， $A$  可以被相似变换成一个上三角矩阵。

具体来说，上三角矩阵的对角线上的元素是  $A$  的特征值，而非对角线上的元素可能为零。

- Schur 分解定理提供了一种将任意方阵转化为上三角形式的方法，从而更容易求解矩阵的特征值。

# 正规矩阵和厄米矩阵的对角化

## 正规矩阵的对角化

正规矩阵  $AA^* = A^*A$  可以通过么正矩阵  $U$  的相似变换对角化, 即:

$$A = UDU^*$$

特征根为复数

## 厄米矩阵的对角化

厄米矩阵  $H = H^*$

- 厄米矩阵总是可以进行**实对角化**, 即可以通过实正交矩阵对角化。  
即:

$$A = Q\Sigma Q^*$$



# Jordan 标准型

## 对角化的条件

当代数多重度（一个特征值的重复次数）大于几何多重度（与特征值相关联的线性独立的本征矢量的数量）时，矩阵无法实现对角化，但可以进行块对角化。

## Jordan 块示例

$$\begin{bmatrix} \lambda & 1 & 0 \\ 0 & \lambda & 0 \\ 0 & 0 & \lambda \end{bmatrix}$$

这是一个  $3 \times 3$  的 Jordan 块，1 是块的上三角部分。特征值 Jordan 块的数量是几何多重度。

## Jordan 标准型

Jordan 标准型是一种矩阵的特殊形式，用于块对角化。它由多个 Jordan 块组成，每个块对应一个特征值。

# Jordan 标准型

## Jordan 标准型

任意  $n \times n$  的复矩阵  $A$  可以通过相似变换转化为 Jordan 标准型:

$$X^{-1}AX = J = \text{Diag}(J_1, J_2, \dots, J_n)$$

其中,  $X$  是可逆矩阵,  $J_i$  是第  $i$  个 Jordan 块。

## Jordan 标准型的稳定性

需要注意的是, Jordan 标准型并不是稳定的。这意味着即使微小的扰动也可能改变矩阵的 Jordan 标准型。

## Jordan 块的数量和对角化条件

Jordan 块的数量等于线性独立的本征矢的数量。矩阵可以对角化的充要条件是每个 Jordan 块都是  $1 \times 1$  的, 即只包含一个特征值。

# 本征值分布与 Gershgorin 圆盘定理

## Gershgorin 圆盘定理

对于任意  $n \times n$  矩阵  $A$  的每个本征值  $\lambda_i$ , 存在至少一个 Gershgorin 圆盘, 其中心是矩阵的对角元素  $a_{ii}$ , 半径是其他同一行元素的绝对值之和:

$$|\lambda_i - a_{ii}| \leq \sum_{j \neq i} |a_{ij}|$$

## Gershgorin 圆盘定理的应用

对于厄米矩阵 (Hermitian matrix), Gershgorin 圆盘定理为求解本征值提供了有用的信息。在搜索本征值时, 可以使用这些圆盘的上下限来缩小搜索范围, 从而更有效地找到本征值。

# 奇异值分解定理

## 奇异值分解定理 (Singular Value Decomposition, SVD)

对于任意复数域上的  $m \times n$  矩阵  $\mathbf{A}$ , 存在以下奇异值分解:

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^*$$

其中,  $\mathbf{U}$  和  $\mathbf{V}$  分别是复数域上的幺正矩阵 (unitary matrices),  $\mathbf{\Sigma}$  是一个大小为  $m \times n$  的对角矩阵, 其对角线上的非负元素称为奇异值 (singular values), 通常按降序排列。

## 奇异值分解的应用

奇异值分解是矩阵分析和线性代数中的重要工具, 广泛应用于数据降维、矩阵逼近、图像压缩、信号处理、推荐系统等领域。它能够揭示数据的主要特征、去除噪声、简化计算, 并为复杂问题提供了有效的数值解法。

# 手算奇异值分解示例

假设我们有一个矩阵  $\mathbf{A}$ :

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix}$$

# 手算奇异值分解示例

假设我们有一个矩阵  $\mathbf{A}$ :

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix}$$

**步骤 1: 计算  $\mathbf{A}\mathbf{A}^T$**

$$\mathbf{A}\mathbf{A}^T = \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix} = \begin{bmatrix} 5 & 8 \\ 8 & 13 \end{bmatrix}$$

# 手算奇异值分解示例

假设我们有一个矩阵  $\mathbf{A}$ :

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix}$$

**步骤 1: 计算  $\mathbf{A}\mathbf{A}^T$**

$$\mathbf{A}\mathbf{A}^T = \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix} = \begin{bmatrix} 5 & 8 \\ 8 & 13 \end{bmatrix}$$

**步骤 2: 计算  $\mathbf{A}^T\mathbf{A}$**

$$\mathbf{A}^T\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix} = \begin{bmatrix} 5 & 8 \\ 8 & 13 \end{bmatrix}$$

# 手算奇异值分解示例 (续)

## 步骤 3: 计算 $\mathbf{A}\mathbf{A}^T$ 的特征值和特征向量

特征方程:  $\det(\mathbf{A}\mathbf{A}^T - \lambda\mathbf{I}) = 0$

计算得到特征值:  $\lambda_1 = 18, \lambda_2 = 0$

对于  $\lambda_1 = 18$ , 求解特征向量:

$$\begin{bmatrix} 5 - 18 & 8 \\ 8 & 13 - 18 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} -13 \\ -5 \end{bmatrix}$$

解得特征向量  $\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$

对于  $\lambda_2 = 0$ , 求解特征向量:

$$\begin{bmatrix} 5 & 8 \\ 8 & 13 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

解得特征向量  $\mathbf{v}_2 = \begin{bmatrix} -8 \\ 5 \end{bmatrix}$



# 手算奇异值分解示例 (续)

## 步骤 4: 计算 $\mathbf{A}^T \mathbf{A}$ 的特征值和特征向量

特征方程:  $\det(\mathbf{A}^T \mathbf{A} - \lambda \mathbf{I}) = 0$

计算得到特征值:  $\lambda_1 = 18, \lambda_2 = 0$

对于  $\lambda_1 = 18$ , 求解特征向量:

$$\begin{bmatrix} 5 - 18 & 8 \\ 8 & 13 - 18 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} -13 \\ -5 \end{bmatrix}$$

解得特征向量  $\mathbf{u}_1 = \begin{bmatrix} -2 \\ 1 \end{bmatrix}$

对于  $\lambda_2 = 0$ , 求解特征向量:

$$\begin{bmatrix} 5 & 8 \\ 8 & 13 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

解得特征向量  $\mathbf{u}_2 = \begin{bmatrix} 2 \\ -1 \end{bmatrix}$

# 手算奇异值分解示例 (续)

## 步骤 5: 构建奇异值分解

我们已经得到特征值和特征向量:

$$\lambda_1 = 18, \mathbf{u}_1 = \begin{bmatrix} -2 \\ 1 \end{bmatrix}, \mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

$$\lambda_2 = 0, \mathbf{u}_2 = \begin{bmatrix} 2 \\ -1 \end{bmatrix}, \mathbf{v}_2 = \begin{bmatrix} -8 \\ 5 \end{bmatrix}$$

奇异值  $\sigma_i$  是特征值的平方根, 按降序排列:

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{18}, \sigma_2 = \sqrt{\lambda_2} = 0$$

构建奇异值矩阵  $\Sigma$  和左右奇异向量矩阵  $\mathbf{U}$ 、 $\mathbf{V}$ :

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix} = \begin{bmatrix} \sqrt{18} & 0 \\ 0 & 0 \end{bmatrix}$$

$$\mathbf{U} = [\mathbf{u}_1 \quad \mathbf{u}_2] = \begin{bmatrix} -2 & 2 \\ 1 & -1 \end{bmatrix}$$

$$\mathbf{V} = [\mathbf{v}_1 \quad \mathbf{v}_2] = \begin{bmatrix} 1 & -8 \\ 2 & 5 \end{bmatrix}$$

# 手算奇异值分解示例 (续)

## 步骤 6: 计算 A 的奇异值分解

现在我们可以计算 A 的奇异值分解了:

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T = \begin{bmatrix} -2 & 2 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} \sqrt{18} & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ -8 & 5 \end{bmatrix}^T$$

计算得到:

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix}$$

这就是矩阵 A 的奇异值分解结果。

# 矩阵模

## 数值求解线性方程组

在计算物理中，我们经常需要求解线性方程组，通常采用数值方法。其中，一个常见的任务是解决形如  $\min \|Ax - b\|$  的问题，其中  $A$  是系数矩阵， $x$  是未知变量， $b$  是右侧向量。

## 诱导矩阵模

对于一个矩阵  $A$ ，其模被定义为：

$$\|A\| = \sup_{\|x\| \neq 0} \frac{\|Ax\|}{\|x\|}$$

其中， $\|x\|$  表示向量  $x$  的模， $\sup$  表示上确界。

- 非负性： $\|A\|$  总是非负的。
- 均匀性： $\|\alpha A\| = |\alpha| \|A\|$  对于所有标量  $\alpha$  成立。
- 三角不等式： $\|A + B\| \leq \|A\| + \|B\|$  对于所有矩阵  $A$  和  $B$  成立。

# 向量 $p$ 模和矩阵 $p$ 模

## 向量 $p$ 模

给定一个  $n$  维实数向量  $\mathbf{x} = (x_1, x_2, \dots, x_n)$  和一个正整数  $p$ , 向量  $p$  模定义如下:

$$\|\mathbf{x}\|_p = \left( \sum_{i=1}^n |x_i|^p \right)^{1/p}$$

这里,  $|x_i|$  表示  $x_i$  的绝对值。

## 诱导的矩阵 $p$ 模

对于一个  $n \times m$  实数矩阵  $\mathbf{A}$ , 其诱导的矩阵  $p$  模定义如下:

$$\|\mathbf{A}\|_p = \sup_{\|\mathbf{x}\|_p \neq 0} \frac{\|\mathbf{Ax}\|_p}{\|\mathbf{x}\|_p}$$

其中,  $\|\mathbf{x}\|_p$  表示向量  $\mathbf{x}$  的  $p$  模。

# $p = 1$ 情况

## 矩阵 1 模

矩阵 1 模表示为：

$$\|\mathbf{A}\|_1 = \max_{\|\mathbf{x}\|_1=1} \|\mathbf{A}\mathbf{x}\|_1$$

## 推导过程

$$\|\mathbf{A}\|_1 = \|\sum_j x_j \mathbf{a}_j\|_1 \leq \sum_j |x_j| \|\mathbf{a}_j\|_1$$

因为  $\sum |x_i| = 1$ , 因此

$$\sum_j |x_j| \|\mathbf{a}_j\|_1 \leq \max_{\|\mathbf{x}\|_1=1} \|\mathbf{A}\mathbf{x}\|_1$$

- 矩阵 1 模是矩阵列和的最大值

# $p = 2$ 情况

## 矩阵 2 模

矩阵 2 模表示为:

$$\|\mathbf{B}\|_2 = \sqrt{\lambda_{\max}(\mathbf{B}^\top \mathbf{B})}$$

## 推导过程

$$\frac{\|\mathbf{B}\vec{x}\|_2}{\|\vec{x}\|_2} = \frac{(\vec{x}^\top \mathbf{B}^\top \mathbf{B} \vec{x})^{\frac{1}{2}}}{(\vec{x}^\top \vec{x})^{\frac{1}{2}}} = \left( \frac{\sum_{i=0}^n \|c_i\|^2 v_i}{\sum_{j=0}^n \|c_j\|^2} \right)^{\frac{1}{2}}$$

其中,  $\vec{x} = \sum_{j=1}^n c_j \vec{\alpha}_j$ ,  $\vec{\alpha}_i$  是  $\mathbf{B}^\top \mathbf{B}$  的本征矢

$$\frac{\|\mathbf{B}\vec{x}\|_2}{\|\vec{x}\|_2} \leq \sqrt{v_n} = \sqrt{\lambda_{\max}(\mathbf{B}^\top \mathbf{B})}$$

若  $\mathbf{B}$  是厄米矩阵  $\|\mathbf{B}\|_2^2 = \lambda_{\max}(B)$